

技术支持材料

下方为甲方需求与乙方提供配置的偏离情况

AI 推理子系统平台

模块	指标要求	供应配置	偏离情况
CPU	配置≥2 颗处理器，单颗处理器基本频率≥2.0GHz，最大睿频频率≥4GHz，内核数≥32，总线程数≥64，缓存≥160MB。	2*Intel 至强金牌 6530 正式版 32 核心 64 线程 2.1G 主频	无偏离
平台	无	朴赛 PGIs454-D08L	无偏离
内存	最大支持 32 根内存，实际配置≥2 根 32GB DDR5 ECC 内存。	2*三星 32G DDR5 4800 RECC 服务器内存	无偏离
SSD	配置≥2 块 1.92T NVME U.2 SSD 硬盘	2*Intel P5530 1.92T U.2 企业级	无偏离
HDD	配置≥1 块 16T SATA HDD 硬盘	希捷 18TB SATA 企业级	无偏离
网卡	配置≥1 块双口万兆网卡，含模块。	Intel10G 双口万兆 X520-SR2 含模块	无偏离
显卡	配置≥8 张 GPU 显卡，单精度性能≥19 TFLOPS，显存≥80G，显存带宽≥1900 GB/sec，支持 PCIe Gen4 及以上接口）。	8*NVIDIA Tesla A100 80G 显存（定制版）	无偏离
电源	配置 4 组冗余机房通用电源，国标插头，满足满功率运行。	高斯宝 2000W 四电 冗余电源	无偏离
机箱	无	4U 机架式（含导轨）	无偏离
技术支持	1、提供服务器面板判断硬件故障功能，包括但不限于系统/内存/电源/风扇/温度/网络等关键部件的故障诊断功能； 2、集成BMC管理模块，支持 IPMI、KVM over IP、虚拟媒体等功能；支持服务器硬件运行监控，包括 CPU 温度、内存使用率、；出入风口温度；风扇转速及风扇占空比。 3、所投服务器具备运行行业主流训练框架（如 PyTorch、TensorFlow、DeepSpeed 等）及主流大模型（如 LLaMA、Qwen、DeepSeek 等）的能力，支持大模型的训练与微调，具备参数微调训练能力。投标人应提供承诺函，承诺在中标后配合采购人完成上述软件环境的部署和验证。	1、提供服务器面板判断硬件故障功能，包括但不限于系统/内存/电源/风扇/温度/网络等关键部件的故障诊断功能； 2、集成 BMC 管理模块，支持 IPMI、KVM over IP、虚拟媒体等功能；支持服务器硬件运行监控，包括 CPU 温度、内存使用率、；出入风口温度；风扇转速及风扇占空比。 3、服务器具备运行行业主流训练框架（如 PyTorch、TensorFlow、DeepSpeed 等）及主流大模型（如 LLaMA、Qwen、DeepSeek 等）的能力，支持大模型的训练与微调，具备参数微调训练能力。承诺在中标后配合采购人完成上述软件环境的部署和验证。 4、针对人工智能领域的特定需求，系统需提供完善的 GPU 等异构	无偏离

4、针对人工智能领域的特定需求，提供 GPU 等异构计算资源管理接口，实现对 CPU、内存、磁盘等资源的虚拟化和统一管理，支持以直通方式挂载 GPU 等异构计算资源。（可通过硬件自带的 BMC/IPMI 功能、开源调度系统（如 Slurm）或第三方商业软件实现，不限定具体产品。投标人应说明其实现方式，中标后配合采购人完成部署。） 5、任务时长功能：限制用户单任务使用时间，可对用户，用户组，全局进行任务使用时间限制。（可通过硬件自带的 BMC/IPMI 功能、开源调度系统（如 Slurm）或第三方商业软件实现，不限定具体产品。投标人应说明其实现方式，中标后配合采购人完成部署。） 6、排队功能：用户使用资源不足时，未超过单个资源池限制，启动排队功能，默认根据用户提交时间排队，管理员可修改用户排队顺序。 7、作业管理：提供训练作业管理功能，包括查看任务运行状态、作业名称、用户、使用资源池，支持作业快速克隆、查看运行日志，作业持续时间显示。 8、作业监控：支持输出损失率、准确率等动态可视化监控图表，同时支持输出训练过程日志，并提供日志查看功能。	计算资源管理接口，实现对 CPU、内存、磁盘等基础资源的虚拟化统一管理与 GPU 直通挂载；具备精细化的作业调度与管控能力，支持针对用户、用户组及全局的任务时长限制，并在资源不足时自动启动排队机制（默认按提交时间排序，且支持管理员人工调整排队顺序）；同时，提供全面的训练作业管理与可视化监控功能，支持查看作业运行状态、名称、所属用户及资源池、作业持续时间等详细信息，具备作业快速克隆与运行日志查看能力，并能动态输出损失率、准确率等可视化监控图表及训练过程日志。上述功能可通过硬件自带的 BMC/IPMI 功能、开源调度系统（如 Slurm）或第三方商业软件实现（不限定具体产品）。	
--	---	--

AI 训练子系统平台

模块	指标要求	供应配置	偏离情况
CPU	配置 ≥ 2 颗处理器，单颗处理器基本频率 $\geq 2.0\text{GHz}$ ，最大睿频频率 $\geq 4\text{GHz}$ ，内核数 ≥ 32 ，总线程数 ≥ 64 ，缓存 $\geq 160\text{MB}$ 。	2*Intel 至强金牌 6530 正式版 32 核心 64 线程 2.1G 主频	无偏离
主板	无	朴赛 PGI454-D08L	无偏离
内存	最大支持 32 根内存，实际配置 ≥ 2 根 32GB DDR5 ECC 内存。	2*三星 32G DDR5 4800 RECC 服务器内存	无偏离
SSD	配置 ≥ 2 块 3.84T NVME U.2 SSD 硬盘	2*Intel P5520 3.84T U.2 企业级	无偏离
HDD	配置 ≥ 2 块 16T SATA HDD 硬盘。	2*希捷 18TB SATA 企业级	无偏离
网卡	配置 ≥ 1 块双口万兆网卡，含模块。	Intel10G 双口万兆 X520-SR2 含模块	无偏离
显卡	配置 ≥ 8 张 GPU 显卡，单精度性能 $\geq 19\text{ TFLOPS}$ ，显存 $\geq 80\text{G}$ ，显存带宽 $\geq 1900\text{ GB/sec}$ ，支持 PCIe Gen4 及以上接口）。	8*NVIDIA Tesla A100 80G 显存（定制版）	无偏离
电源	配置 4 组冗余机房通用电源，国标插头，满足满功率运行。	高斯宝 2000W 四电 冗余电源	无偏离
机箱	无	4U 机架式（含导轨）	无偏离
技术支持	1、 提供服务器面板判断硬件故障功能,包括但不限于系统/内存/电源/风扇/温度/网络等关键部件的故障诊断功能； 2、 集成 BMC 管理模块，支持 IPMI、KVM over IP、虚拟媒体等功能；支持服务器硬件运行监控，包括 CPU 温度、内存使用率、；出入风口温度；风扇转速及风扇占空比。 3、 所投服务器具备运行行业主流训练框架（如 PyTorch、TensorFlow、DeepSpeed 等）及主流大模型（如 LLaMA、Qwen、DeepSeek 等）的能力，支持大模型的训练与微调,具备参数微调训练能力。投标人应提供承诺函，承诺在中标后配合采购人完成上述软件环境的部署和验证。 4、 针对人工智能领域的特定需	1、 提供服务器面板判断硬件故障功能，包括但不限于系统/内存/电源/风扇/温度/网络等关键部件的故障诊断功能； 2、 集成 BMC 管理模块,支持 IPMI、KVM over IP、虚拟媒体等功能；支持服务器硬件运行监控，包括 CPU 温度、内存使用率、；出入风口温度；风扇转速及风扇占空比。 3、 服务器具备运行行业主流训练框架（如 PyTorch、TensorFlow、DeepSpeed 等）及主流大模型（如 LLaMA、Qwen、DeepSeek 等）的能力，支持大模型的训练与微调，具备参数微调训练能力。承诺在中标后配合采购人完成上述软件环境的部署和验证。 4、 针对人工智能领域的特定需求，系统需提供完善的 GPU 等异构计算资源管理接口，实现对 CPU、内存、磁盘等基础资源的虚拟化统一管理	无偏离

	求,提供 GPU 等异构计算资源管理接口,实现对 CPU、内存、磁盘等资源的虚拟化和统一管理,支持以直通方式挂载 GPU 等异构计算资源。(可通过硬件自带的 BMC/IPMI 功能、开源调度系统(如 Slurm)或第三方商业软件实现,不限定具体产品。投标人应说明其实现方式,中标后配合采购人完成部署。) 5、 任务时长功能:限制用户单任务使用时间,可对用户,用户组,全局进行任务使用时间限制。(可通过硬件自带的 BMC/IPMI 功能、开源调度系统(如 Slurm)或第三方商业软件实现,不限定具体产品。投标人应说明其实现方式,中标后配合采购人完成部署。) 6、 排队功能:用户使用资源不足时,未超过单个资源池限制,启动排队功能,默认根据用户提交时间排队,管理员可修改用户排队顺序。 7、 作业管理:提供训练作业管理功能,包括查看任务运行状态、作业名称、用户、使用资源池,支持作业快速克隆、查看运行日志,作业持续时间显示。 8、 作业监控:支持输出损失率、准确率等动态可视化监控图表,同时支持输出训练过程日志,并提供日志查看功能。	与 GPU 直通挂载;具备精细化的作业调度与管控能力,支持针对用户、用户组及全局的任务时长限制,并在资源不足时自动启动排队机制(默认按提交时间排序,且支持管理员人工调整排队顺序);同时,提供全面的训练作业管理与可视化监控功能,支持查看作业运行状态、名称、所属用户及资源池、作业持续时间等详细信息,具备作业快速克隆与运行日志查看能力,并能动态输出损失率、准确率等可视化监控图表及训练过程日志。上述功能可通过硬件自带的 BMC/IPMI 功能、开源调度系统(如 Slurm)或第三方商业软件实现(不限定具体产品)。	
--	--	--	--

下面为提供硬件参考

(一) CPU: Intel 至强金牌 6530 正式版

详细参数: 2.1GHz 主频 32 核心 64 线程 最大睿频 4GHz 160MB 三级缓存 支持内存 DDR5, 最大支持 8 内存通道

产品链接: <https://www.intel.cn/content/www/cn/zh/products/sku/237249/intel-xeon-gold-6530-processor-160m-cache-2-10-ghz/specifications.html>





SPEC CPU®2017 Integer Rate Result

Copyright 2017-2024 Standard Performance Evaluation Corporation

IEIT Systems Co., Ltd.

SPECrate®2017_int_base = 555

NF5468M7 (Intel Xeon Gold 6530)

SPECrate®2017_int_peak = 572

CPU2017 License: 3358


Test Sponsor: IEIT Systems Co., Ltd.

Tested by: IEIT Systems Co., Ltd.

Test Date: Jun-2024

Hardware Availability: Dec-2023

Software Availability: Dec-2023



Hardware

CPU Name: Intel Xeon Gold 6530
Max MHz: 4000
Nominal: 2100
Enabled: 64 cores, 2 chips, 2 threads/core
Orderable: 1,2 chips
Cache L1: 32 KB I + 48 KB D on chip per core
L2: 2 MB I+D on chip per core
L3: 160 MB I+D on chip per chip
Other: None
Memory: 1 TB (16 x 64 GB 2Rx4 PC5-5600B-R, running at 4800)
Storage: 1 x 1.92 TB NVME SSD
Other: CPU Cooling: Air

Software

OS: SUSE Linux Enterprise Server 15 SP5
5.14.21-150500.53-default
Compiler: C/C++: Version 2024.0.2 of Intel oneAPI DPC++/C++ Compiler for Linux;
Fortran: Version 2024.0.2 of Intel Fortran Compiler for Linux;
Parallel: No
Firmware: Version 05.13.00 released Nov-2023
File System: xfs
System State: Run level 3 (multi-user)
Base Pointers: 64-bit
Peak Pointers: 32/64-bit
Other: jemalloc memory allocator V5.0.1
Power Management: BIOS set to prefer performance at the cost of additional power usage.

	SPEC CPU®2017 Integer Rate Result													
Copyright 2017-2024 Standard Performance Evaluation Corporation														
IEIT Systems Co., Ltd.								SPECrate®2017_int_base = 555						
NF5468M7 (Intel Xeon Gold 6530)								SPECrate®2017_int_peak = 572						
CPU2017 License: 3358								Test Date: Jun-2024						
Test Sponsor: IEIT Systems Co., Ltd.								Hardware Availability: Dec-2023						
Tested by: IEIT Systems Co., Ltd.								Software Availability: Dec-2023						
Results Table														
Benchmark	Base							Peak						
	Copies	Seconds	Ratio	Seconds	Ratio	Seconds	Ratio	Copies	Seconds	Ratio	Seconds	Ratio	Seconds	Ratio
500.perlbench_r	128	474	430	475	429	475	429	128	433	470	433	470	433	471
502.gcc_r	128	363	499	362	500	363	500	128	309	586	309	587	310	586
505.mcf_r	128	226	917	226	916	227	912	128	226	917	226	916	227	912
520.omnetpp_r	128	421	399	421	399	421	399	128	421	399	421	399	421	399
523.xalancbmk_r	128	177	765	176	766	177	765	128	177	765	176	766	177	765
525.x264_r	128	208	1080	208	1080	208	1080	128	198	1130	198	1130	198	1130
531.deepsjeng_r	128	391	375	391	375	391	375	128	391	375	391	375	391	375
541.leela_r	128	582	364	581	365	581	365	128	582	364	581	365	581	365
548.exchange2_r	128	298	1120	298	1130	298	1120	128	298	1120	298	1130	298	1120
557.xz_r	128	492	281	498	278	498	278	128	492	281	498	278	498	278
SPECrate®2017_int_base = 555														
SPECrate®2017_int_peak = 572														
Results appear in the order in which they were run. Bold underlined text indicates a median measurement.														
Submit Notes														
The numactl mechanism was used to bind copies to processors. The config file option 'submit' was used to generate numactl commands to bind each copy to a specific processor. For details, please see the config file.														
Operating System Notes														
Stack size set to unlimited using "ulimit -s unlimited"														
Environment Variables Notes														
Environment variables set by runcpu before the start of the run: LD_LIBRARY_PATH = "/home/CPU2017/lib/intel64:/home/CPU2017/lib/ia32:/home/CPU2017/je5.0.1-32" MALLOCONF = "retain:true"														
General Notes														
Binaries compiled on a system with 2x Intel Xeon Platinum 8280M CPU + 384GB RAM memory using Red Hat Enterprise Linux 8.4 Transparent Huge Pages enabled by default Prior to runcpu invocation Filesystem page cache synced and cleared with: sync; echo 3> /proc/sys/vm/drop_caches runcpu command invoked through numactl i.e.: numactl --interleave=all runcpu <etc>														
NA: The test sponsor attests, as of date of publication, that CVE-2017-5754 (Meltdown) is mitigated in the system as tested and documented. Yes: The test sponsor attests, as of date of publication, that CVE-2017-5753 (Spectre variant 1) is mitigated in the system as tested and documented. Yes: The test sponsor attests, as of date of publication, that CVE-2017-5715 (Spectre variant 2)														
(Continued on next page)														
Page 2			Standard Performance Evaluation Corporation (info@spec.org)							https://www.spec.org/				

链接: <https://www.spec.org/cpu2017/results/res2024q3/cpu2017-20240715-44114.pdf>

(二) 平台：朴赛 PGI454-D08L

详细参数：支持 2 颗 s 英特尔®至强®第四代或第五代可扩展处理器或澜起津逮®系处理器、支持 8 张 450W 双宽全高全长 GPU、支持 32 个 DDR5 内存、支持 8 卡直连

产品链接：https://www.puersai.com/UserFiles/Article/download/%E6%9C%B4%E8%B5%9BPGI454-D08%E4%BA%A7%E5%93%81%E5%BD%A9%E9%A1%B5_muNUWTgb.pdf

PUEPSAI 朴赛

AI服务器及定制化解决方案领航者

朴赛PGI454-D08 旗舰型 AI 服务器



朴赛PGI454-D08 是一款双路LGA677平台4U机架式8卡GPU服务器 基于最大支持2颗英特尔®至强®第四代或第五代可扩展处理器，配合8通道4800MT/s DDR5内存技术，为用户提供高达50%的带宽提升。通过20个PCIe 5.0插槽，实现灵活的扩展能力。5°C ~ 40°C的标准工作温度设计，为用户提供更高的能效回报。



极致性能为AI而生

- ◆ 支持 2 颗英特尔®至强®第四代或第五代可扩展处理器或澜起津逮®系列处理器，支持最高 385W 功耗，计算性能强劲；
- ◆ 支持 8 张 450W 双宽全高全长 GPU，大幅提升异构算力；
- ◆ 支持 GPU 到 CPU x32 传输带宽，比业界x16 翻倍，满足 CPU 与 GPU 高通信带宽场景要求；
- ◆ 支持 32 个 DDR5 内存，频率最高可达 5600MHz，为用户提供高达60%的带宽提升。



领先架构

- ◆ 支持 8 卡直连，支持多种 GPU 拓扑配置，灵活匹配不同应用场景需求；
- ◆ 超高扩展能力，支持最多 11 个标准 PCIe 插槽，可配置 8 个双宽 GPU+3 个 PCIe 标准插卡+1 个 OCP 3.0 网卡；
- ◆ 存储配置根据需求灵活更换，满足大容量和高性能的本地存储需求，最大支持 4 个 U.2。



稳定可靠 智能管理

- ◆ 系统关键部件均采用冗余、热插拔设计，同时支持免工具拆装，提升故障维护效率，提升系统的可用性；
- ◆ 集成智能管理芯片，提供开放的管理平台，支持 IPMI2.0、Redfish、SNMP 等多种管理协议；
- ◆ 支持远程 KVM、虚拟媒介、关键部件状态监控、异常报警等各种管理功能，实现了全面的远程系统级智能管理。

方案	4U 8卡-直通
处理器	支持 2 颗 英特尔®至强®第四代或第五代可扩展处理器或澜起津逮®处理器系列，最大功率 385W
内存	最大支持32根DDR5内存，最高速率5600MT/s，
内存类型	支持RDIMM或LRDIMM，最大支持 8TB 内存
存储控制器	可选配高性能RAID控制器, 支持RAID0/1/10/5/6/50/60
存储扩展	系统SAS/SATA/NVMe硬盘配置： 支持 12块3.5寸/2.5 英寸硬盘 （默认2个NVME+10个SATA）
PCIe扩展	支持8个x16标准PCIe扩展槽位 支持1个OCP 3.0槽位 后置支持3个X8的PCIe 插槽
网络	支持1个OCP3.0网卡，可选配1/10/25/50/100/200/400GE PCIe标准网卡， 可选配双宽DPU标准网卡
I/O 端口	前置：2 个 USB 3.0 后置：1个串口，2个USB 3.0接口，1 个 VGA 接口，1个RJ45 管理口
管理软件	集成BMC管理芯片AST2600，支持IPMI2.0、Redfish、SOL、KVM、虚拟媒介等功能
安全性	支持机箱入侵检测；支持Intel PFR3.0和SGX2.0安全技术；支持TCM/TPM安全模块
电源	支持4个2000W/2400W/2700W 可选钛金电源，支持N+N冗余/N+1冗余
风扇	风扇支持8个8056风扇，N+1热插拔冗余风扇
机箱尺寸	4U机箱 175mm（高）×447mm（宽）×828mm（深）
工作温度	5℃～40℃（工作温度支持受不同配置影响）
工作相对湿度	8%-90%(无冷凝)
支持操作系统	Microsoft Windows Server, Red Hat Enterprise Linux,SUSE Linux Enterprise Server, CentOs, Ubuntu. Oracle Linux、VMware ESXi、Citrix XenServer等，具体版本请向销售人员咨询

（三） 内存：三星 32G DDR5 4800 RECC 服务器内存

详细参数：DDR5 内存颗粒 32G 单根容量 具有 ECC 纠错功能 具有寄存器 4800MHz 频率

产品链接：<https://semiconductor.samsung.cn/dram/ddr/ddr5/>


五代双倍数据率同步动态随机存储器带来以数据为中心的创新

五代双倍数据率同步动态随机存储器满足了正在经历数据巨大爆发的行业的需求。五代双倍数据率同步动态随机存储器融合了新的速度水平、改善的容量和加强的可靠性，以提高整体系统性能。三星的内存技术通过节能五代双倍数据率同步动态随机存储器推动了下一个环保创新时代的到来。



专为大量实时数据服务的超快速度

五代双倍数据率同步动态随机存储器具有高达 7200 百万比特/秒 (Mbps) 的卓越传输速度，有效处理对更大、更复杂数据工作量不断增长的需求。与四代双倍数据率同步动态随机存储器相比，五代双倍数据率同步动态随机存储器的性能提升了一倍多，突发长度从 8 翻倍至 16，存储库数量从 16 翻倍至 32。令人惊叹的性能提升了大数据处理的天花板，同时无缝处理 8K 内容。




4倍容量，助力行业创新

三星已采用12纳米级工艺技术、硅通孔(TSV)和极紫外光刻(EUV)技术，开发出目前三星最大的1TB容量DDR5内存模组。
4倍容量，助力用户流畅处理同时发生的多个繁重工作负载，并具备未来创新可扩展性。



具备自纠错解决方案的强大可靠性

应用于 五代双倍数据率同步动态随机存储器 的 ODECC（片上纠错码）技术帮助保持安全稳定的数据可靠性，以完全利用强大的性能。ODECC 几乎消除了单比特错误，从而提高了可靠性，即使在大数据的繁重需求下也是如此。



（四）固态硬盘：Intel P5530 1.92T U.2 企业级

详细参数:1.92TB 单盘容量，U.2（2.5 英寸）规格固态硬盘，支持 NVMe 协议，顺序读取速度可达 6500MB/s。

产品链接: <https://www.solidigmtech.com.cn/products/data-center/d7/p5520.html>



Product Brief
TLC 3D NAND SSDs

The Industry's Most Advanced PCIe 4.0 Portfolio.¹

Performance-Tuned for the Real World.



Our broadest and highest-performing family of TLC 3D NAND SSDs, Solidigm™ D7-P5520 and D7-P5620 drives (formerly Intel®), are the latest addition to the performance-optimized D7 series. These drives provide standard endurance and medium endurance, respectively, across an extended range of capacities and form factors. Building from multiple generations of PCIe 4.0 and deep industry insight, this is the industry's most advanced PCIe 4.0 portfolio with performance tuned for real-world applications. They efficiently accelerate compute and storage workloads in cloud and enterprise across a breadth of 1U and 2U server configurations. Designed and tested with zero tolerance for data errors² and consistently durable performance,³ they can be deployed with the utmost confidence.

Product series highlights

Compared to the previous generation of PCIe 4.0 products, performance has been significantly boosted across the board, enabling workload acceleration in mixed and read-intensive applications.

Read intensive

	4K Random workload (Higher is better)		Quality of service (4 KB, lower is better)
	4K Random read	4K Random write	Random read (QD1) 4 9s
3.84 TB Solidigm D7-P5520⁴ (versus 3.84 TB Solidigm D7-P5510)	Up to 42% higher	Up to 17% higher	Up to 43% better

Write intensive

	4K random workload (Higher is better)		Quality of service (4 KB, lower is better)
	4K Random read	4K Random write	Random write (QD1), 6 9s
3.2 TB Solidigm D7-P5620,⁵ R/W: 1,000K/341K (versus 3.2 TB Solidigm DC P4610, R/W: 638K/222K)	Up to 56% higher	Up to 53% higher	Up to 76% better

1

Form factor and capacity expansion enable server modernization opportunities spanning a broad range of 1U and 2U configurations for compute and storage servers.



With NAND media, firmware, and controllers common to all SKUs in the D7-P5520 and D7-P5620 series, customers have an opportunity to ease qualifications across form factors and capacities, given the possibility of data sharing.

Advanced feature set

Building on our previous generation PCIe 4.0 data center SSDs, the Solidigm D7-P5520 and D7-P5620 offer a wide range of new features (in addition to features supported by the Solidigm D7-P5510) that are essential to building modern data centers. Some of the notable drive features include:

Features	Benefits
PCIe VDM support through MCTP, enhanced SMART monitoring, support for cloud C0 log page, and NVMe Express (NVMe) MI 1.1	Reports drive health status without disrupting the I/O data flow over both PCIe and SMBus.
Variable sector size	Support for multiple sector sizes: 512/520/4,096/4,104/4,160 B. Expanded LBA format support provides flexibility to host software to pass metadata and protection information along with payload data.
Drive and data security—OPAL 2.0, configurable namespace locking, sanitize, secure erase	Enables drive-level security for data at rest.
Scatter gather list with dataset management	Improves performance by removing the need for data alignment at the host with concurrent TRIM operations.
Improved telemetry logs	Makes a wide range of stored data accessible and includes intelligent error tracking and logging increasing the reliability of finding and mitigating issues. It also support accelerated qualification cycles—all of which can result in increased IT efficiency.
Dynamic multiple namespaces	Enhances runtime provisioning and storage management. Overprovisioning of drives with single, smaller namespaces can improve endurance and random write performance.
Device self-test	Improves customer experiences by helping ensure devices operate as expected. The host system can request the storage device (SSD) to perform tests to ensure it is functioning properly, including SMART check, volatile memory backup, NVMe integrity, and drive life.

Optimized for real-world cloud and enterprise storage workloads

Overall performance improvements combined with our deep, industry-wide technical insight deliver performance tuned for the real world, helping to efficiently accelerate compute and storage workloads for cloud and enterprise.

Examples of unlocking cloud storage workloads—Cloud compute services are used across a range of scenarios such as data backup, disaster recovery, databases, email, and virtual desktop. These usages present a highly random, mixed workload environment valuing low latency to improve the user experience, and the Solidigm D7-P5520 delivers nearly 11%⁶ better response time than prior-generation drives. Server-based storage solutions using virtualization software are another common cloud storage workload. VMs in these workloads create a mix of reads and writes that can be random or sequential. Compared to prior-generation drives, the Solidigm D7-P5520 accelerates these workloads with up to 13% better random read IOPS and up to 11% better sequential write throughput.⁷

Examples of unlocking enterprise storage workloads—As the name implies, general purpose servers (GPS) support a range of workloads that can span databases, email, unified communications, content delivery, and more. Given the nature of these servers, throughput and latency in a mixed environment is valued. Compared to the prior generation, the Solidigm SSD D7-P5520 accelerates 80/20 sequential/random read throughput up to 15% and reduces latency up to 13.5%.⁸ Data pipelines serving advanced workloads such as big data, machine learning, and AI are increasingly deployed in enterprises. I/O patterns vary widely through the pipeline phases, and the Solidigm D7-P5520 delivers with up to 7 % better throughput for data-ingestion workloads, up to 6.7% read latency improvement in a 50/50 workload for data preparation, and up to 23.7% higher random read IOPS for training workloads compared to the prior generation.⁹

TCO savings opportunities

Whether solving for storage-footprint optimization or for performance density, expanded capacity ranges and accelerated performance enable a range of cost-saving opportunities.

2U server examples

15.36 TB D7-P5520 versus 8 TB DC P4510		15.36 TB D7-P5520 versus 8TB DC P4510	
Targeting 368 TB capacity ¹⁰		Targeting 10M IOPS ¹¹	
Space	50% smaller footprint	Space	50% smaller footprint
Power	44% reduction	Power	28% reduction
		Power efficiency (IOPS/Watt)	43% better

Deploy with confidence

Solidigm D7-P5520 and Solidigm D7-P5620 drives are designed and tested with a passion for—and a relentless focus on—quality, reliability, and consistency, so you can deploy them with confidence.

Quality and reliability designed into every drive:

- In-house design or design control of all critical components
- Robust third-party component quality assurance (QA) program
- Enhanced Power Loss Management firmware checks to ensure data accuracy¹²

Drives validated and tested above and beyond:

- **Data reliability:** Data reliability is enhanced on multiple levels with PLI testing that simulates real-world conditions, UBER testing to 10x beyond JEDEC specification, and SDC testing at the highest levels in the industry.²
- **Drive reliability:** Proven reliability delivers AFR significantly better than JEDEC in high-volume manufacturing.¹³ Robust RDT and margin-corner testing helps ensure drives perform reliably in real-world conditions.
- **Consistency:** Up to 90% IOPS consistency and <0.3% IOPS variability provides consistent performance over life of the drive³

Product Brief | The Industry's Most Advanced PCIe 4.0 Portfolio.' Performance-Tuned for the Real World.

To learn more about how Solidigm D7-P5520 and Solidigm D7-P5620 drives can help you unlock the value of your data, visit our value calculator at: [Solidigm.com](https://solidigm.com).

Performance and features at a glance		
Model	Solidigm D7-P5520	Solidigm D7-P5620
Capacity and form factor	U.2 15 mm: 1.92 TB, 3.84 TB, 7.68 TB, 15.36 TB E1.S 9.5 mm/15 mm: 1.92 TB, 3.84 TB, 7.68 TB E1.L 9.5 mm: 15.36 TB	U.2 15 mm: 1.6 TB, 3.2 TB, 6.4 TB, 12.8 TB
Interface	PCIe 4.0 x4, NVMe 1.4, NVMe-MI 1.1	
Drive manageability	NVMe-MI 1.1, PCIe over vendor-defined messages (VDM), PCIe over Management Component Transport Protocol (MCTP), OCP cloud C0 log page support	
Media	Solidigm 144-L 3rd generation 3D NAND (formerly Intel®)	
Performance	4K random read/write up to 1.1M/220K IOPS	4K random read/write up to 1.1M/390K IOPS
	128K sequential read/write up to 7,100/4,200 megabytes per second (MB/s)	128K sequential read/write up to 7,100/4,200 megabytes per second
Endurance (DWPD, 5 years)	Up to 1	Up to 3
Warranty	Five-year limited warranty	

（五）机械硬盘：希捷 18TB SATA 企业级

详细参数：单盘 18TB 容量 U.2 接口 带宽 6Gb/s 7200RPM 氦气密封 企业级机械硬盘

产品链接：https://www.seagate.com/content/dam/seagate/migrated-assets/www-content/datasheets/pdfs/exos-xl8-channel-DS2045-4-2106CN-zh_CN.pdf



产品资料

可扩展，响应灵敏，创新性。

Exos X18



Seagate制造专为满足有大规模云可扩展性需求的硬盘。作为Seagate®X系列的旗舰产品，Exos®X18企业级硬盘是这一系列中容量较大的硬盘。



出色应用

- 可扩展大规模应用/云数据中心
- 海量横向扩展数据中心
- 大数据应用
- 高容量密集型RAID存储
- 主流企业级外置存储阵列
- 分布式文件系统，包括Hadoop和Ceph
- 企业级备份和恢复 —— D2D、虚拟磁带
- 集中监控

实现高机架空间效率的大存储容量

1.市场的18TB HDD，具备一些容量，可在每个机架中提供较多PB的空间

2.高度可靠的性能，搭载增强型缓存，使其成为云数据中心和大规模横向扩展数据中心应用的理想之选

3.大规模SATA，型号针对大型数据传输进行了调整，可实现低延迟。

4.力量平衡™，功能优化了单位TB功耗

5.大限度地降低总体拥有成本，通过氦气密封硬盘设计降低功率和重量

6.久经考验的氦气侧面密封焊接技术实现增强的处理坚固性和泄漏保护

7.数字环境传感器可监控内置硬盘状况，实现运行和性能优化

8.数据保护和安全——Seagate Secure™功能可安全、实惠、快速和轻松地报废硬盘

9.久经考验的企业级可靠性，由5年有限责任质保和250万小时MTBF评级支持



规格	SATA 6Gb/秒	12Gb/秒SAS	SATA 6Gb/秒	12Gb/秒SAS	SATA 6Gb/秒
容量	18TB	18TB	16TB	16TB	14TB
标准型号快速格式 ™ (512e/4Kn) ¹	ST18000NM000J	ST18000NM004J	ST16000NM000J	ST16000NM004J	ST14000NM000J
自加密驱动器型号 快速格式 (512e/4Kn) ^{1,2}	ST18000NM001J	ST18000NM005J	ST16000NM001J	ST16000NM005J	ST14000NM001J
自加密驱动器（符合FIPS标准）快速 格式化技术™ (512e/4Kn) ^{1,2}	—	ST18000NM007J	—	ST16000NM007J	—
功能					
氮气密封硬盘设计	是	是	是	是	是
传统磁记录 (CMR)	是	是	是	是	是
保护信息(T10 DIF)	—	是	—	是	—
奇偶校验	是	是	是	是	是
低卤素	是	是	是	是	是
电力™闲置功率技术	是	是	是	是	是
力量平衡™功率/性能技术	是	是	是	是	是
热插拔支持 ³	是	是	是	是	是
多段缓存 (MB)	256	256	256	256	256
有机可焊性防护层	是	是	是	是	是
RSA 3072固件验证 (SD&D)	是	是	是	是	是

可靠性/数据完整性					
平均故障间隔时间 (MTBF, 小时)	2,500,000	2,500,000	2,500,000	2,500,000	2,500,000
24×7不间断运行的可靠性级别 (AFR)	0.35%	0.35%	0.35%	0.35%	0.35%
不可恢复错误/被读数据 (位)	1 扇区/10E15	1 扇区/10E15	1 扇区/10E15	1 扇区/10E15	1 扇区/10E15
每年运行小时数 (24×7)	8,760	8,760	8,760	8,760	8,760
512e扇区大小 (每扇区字节数)	512	512, 520, 528	512	512, 520, 528	512
4Kn扇区大小 (每扇区字节数)	4,096	4,096, 4,160, 4,224	4,096	4,096, 4,160, 4,224	4,096, 4096
质保年限	5	5	5	5	5
性能					
转速 (RPM)	7,200	7,200	7,200	7,200	7,200
接口访问速度 (Gb/秒)	6.0, 3.0	12.0, 6.0, 3.0	6.0, 3.0	12.0, 6.0, 3.0	6.0, 3.0
较大持续数据传输率OD (MB/秒, MiB/秒)	270/258	270/258	270/258	270/258	270/258
随机读取/写入4K QD16 WCD (IOPS)	170/550	170/550	170/550	170/550	170/550
平均延迟 (毫秒)	4.16	4.16	4.16	4.16	4.16
接口端口	单	双	单	双	单
抗旋转振动性达20-1500赫兹 (弧度/秒 ²)	12.5	12.5	12.5	12.5	12.5
功耗					
平均闲置功率 (瓦)	5.3	5.6	5.1	5.5	4.9
较大运行功耗、随机读/写4K/16Q (瓦)	9.4, 6.4	9.8, 7.0	9.4, 6.4	9.6, 6.7	9.2, 6.3
电源要求	+12V 和 +5V	+12V 和 +5V	+12V 和 +5V	+12V 和 +5V	+12V 和 +5V

环境					
硬盘报告运行温度 (°C)	5 ~ 60	5 ~ 60	5 ~ 60	5 ~ 60	5 ~ 60
振动, 非运行时: 2 赫兹到500赫兹 (Grms)	2.27	2.27	2.27	2.27	2.27
抗冲性, 运行时2 毫秒 (读/写) (G)	50	50	50	50	50
非运行时抗冲击 性: 2毫秒(GS)	200	200	200	200	200
物理规格					
厚度 (英寸/毫米, 较大) ²	1.028 英寸/26.1 毫米	1.028 英寸/26.1 毫米	1.028 英寸/26.1 毫米	1.028 英寸/26.1 毫米	1.028 英寸/26.1 毫米
较大宽度 (英寸/毫 米) ²	4.01 英 寸/101.85 毫米	4.01 英 寸/101.85 毫米	4.01 英 寸/101.85 毫米	4.01 英 寸/101.85 毫米	4.01 英 寸/101.85 毫米
较大深度 (英寸/毫 米) ²	5.787 英寸/147 毫米	5.787 英寸/147 毫米	5.787 英寸/147 毫米	5.787 英寸/147 毫米	5.787 英寸/147 毫米
重量 (克/磅)	670 克/1.477 磅	670 克/1.477 磅	670 克/1.477 磅	670 克/1.477 磅	650 克/1.433 磅
纸箱单位数量	20	20	20	20	20
箱数/托盘 / 箱数/ 层	40/8	40/8	40/8	40/8	40/8

1 FastFormat模块以512e格式状态交付。执行FastFormat 程序从512e切换到4Kn时, 硬盘的所有数据将被删除。请注意, 数据必须对齐为4K扇区, 才能看到4Kn格式的性能提升。

2 自加密硬盘 (SED) 和经FIPS140-2 验证的硬盘可通过特许授权经销商获取。可能需要符合TCG标准的主机或控制器支持。

3 根据串行ATA修订3.3规格支持热插拔操作。


4 基础尺寸符合《小外形尺寸标准》(SFF-8301)。

5 以上参数仅供参考, 以实际购买产品为准。

（六） 显卡：NVIDIA Tesla A100 80G 显存（定制版）

详细参数：6912 CUDA 核心 PCIe 4.0 显存容量 80GB 400W 功耗 Ampere 架构


产品链接：<https://www.nvidia.com/zh-tw/data-center/a100/>





NVIDIA A100 TENSOR CORE GPU

在各种规模上实现出色的加速



适用于各种工作负载的强大计算平台

NVIDIA A100 Tensor Core GPU 可在各个规模下为 AI、数据分析和高性能计算 (HPC) 应用提供出色的加速性能，为全球的高性能弹性数据中心提供强劲助力。作为 NVIDIA 数据中心平台的引擎，与前一代 NVIDIA Volta™ 相比，A100 可使性能提升高达 20 倍。A100 可高效扩展，也可借助多实例 GPU (MIG) 技术划分为 7 个独立的 GPU 实例，从而提供统一的平台，助力弹性数据中心根据不断变化的工作负载需求动态进行调整。

NVIDIA A100 Tensor Core 技术支持广泛的数学精度，可针对每个工作负载提供单个加速器。最新一代 A100 80GB 将 GPU 显存加倍，提供 2TB/s 的全球超快显存带宽，可加速处理超大型模型和海量数据集。

A100 是完整 NVIDIA 数据中心解决方案的一部分，该解决方案由硬件、网络、软件、库以及 NGC™ 目录中经优化的 AI 模型和应用等叠加而成。作为适用于数据中心且功能强大的端到端 AI 和 HPC 平台，A100 可助力研究人员获得真实的结果，并能将解决方案大规模部署到生产环境中。

NVIDIA A100 TENSOR CORE GPU 规格 (SXM4 和 PCIe 外形规格)


	A100 80GB PCIe	A100 80GB SXM
FP64	9.7 TFLOPS	
FP64 Tensor Core	19.5 TFLOPS	
FP32	19.5 TFLOPS	
Tensor Float 32 (TF32)	156 TFLOPS 312 TFLOPS*	
BFLOAT16 Tensor Core	312 TFLOPS 624 TFLOPS*	
FP16 Tensor Core	312 TFLOPS 624 TFLOPS*	
INT8 Tensor Core	624 TOPS 1248 TOPS*	
GPU 显存	80GB HBM2e	80GB HBM2e
GPU 显存带宽	1935GB/s	2039GB/s
最大热设计功耗 (TDP)	300 瓦	400 瓦***
多实例 GPU	最多 7 个 MIG 每个 10GB	最多 7 个 MIG 每个 10GB
外形规格	PCIe 双插槽风冷式或单插槽 液冷式	SXM
互连技术	搭载 2 个 GPU 的 NVIDIA® NVLink® 桥接器： 600GB/s** PCIe 4.0：64GB/s	NVLink：600GB/s PCIe 4.0：64GB/s
服务器选项	搭载 1 至 8 个 GPU 的 合作伙伴认证系统和 NVIDIA 认证系统 (NVIDIA-Certified Systems™)	搭载 4 个、8 个或 16 个 GPU 的 NVIDIA HGX™ A100 合作伙伴认证系统和 NVIDIA 认证系统 搭载 8 个 GPU 的 NVIDIA DGX™ A100

* 采用稀疏技术

** SXM4 GPU 通过 HGX A100 服务器主板连接；PCIe GPU 通过 NVLink 桥接器可桥接多达两个 GPU

*** 400 瓦 TDP (适用于标准配置)。HGX A100-80 GB 自定义散热解决方案 (CTS) SKU 可支持高达 500 瓦的 TDP

跨工作负载的卓越性能



突破性的创新

NVIDIA AMPERE 架构

无论是使用 MIG 将 A100 GPU 分割为较小的实例, 还是使用 NVLink 连接多个 GPU 来加速大规模工作负载, A100 均可轻松满足不同规模的加速需求, 从小型作业到大型多节点工作负载无一例外。A100 功能全面, 这意味着 IT 经理可以全天候地充分利用数据中心内的每个 GPU。

第三代 TENSOR CORE 技术

NVIDIA A100 的深度学习运算性能可达 312 teraFLOPS (TFLOPS)。其深度学习训练的 Tensor 每秒浮点运算次数 (FLOPS) 和推理的 Tensor 每秒万亿次运算次数 (TOPS) 皆为 NVIDIA Volta™ GPU 的 20 倍。

新一代 NVLINK

A100 中采用的 NVIDIA NVLink 可提供两倍于上一代的吞吐量。与 NVIDIA NVSwitch™ 结合使用时, 此技术可将多达 16 个 A100 GPU 互连, 并将速度提升至 600GB/s, 从而在单个服务器上实现出色的应用性能。NVLink 技术可应用在 A100 中: SXM GPU 通过 HGX A100 服务器主板连接, PCIe GPU 通过 NVLink 桥接器可桥接多达两块 GPU。

多实例 GPU (MIG) 技术

一个 A100 GPU 最多可划分为 7 个 GPU 实例, 这些实例在硬件级别完全独立, 并独自拥有高带宽显存、缓存和计算核心。借助 MIG, 开发者可为其所有应用实现惊人加速, IT 管理员也可为每个作业提供符合其规模的 GPU 加速, 进而优化 GPU 利用率, 并让每个用户和应用都能使用 GPU 实例。

高带宽显存 (HBM2E)

凭借 80GB 的高带宽显存 (HBM2e), A100 提供超过 2TB/s 的超快 GPU 显存带宽, 并将动态随机存取存储器 (DRAM) 的利用效率提高至 95%。A100 提供的显存带宽是上一代产品的 1.7 倍。

结构化稀疏

AI 网络拥有数百万至数十亿个参数。实现准确预测并非要使用所有参数, 而且我们还可将某些参数转换为零, 以在无损准确性的前提下使模型变得“稀疏”。A100 中的 Tensor Core 可为稀疏模型提供高达 2 倍的性能提升。稀疏功能不仅更容易使 AI 推理受益, 同时还能提升模型的训练性能。

NVIDIA A100 Tensor Core GPU 是 NVIDIA 数据中心平台的旗舰产品，可用于深度学习、高性能计算 (HPC) 和数据分析。该平台可为 2000 余款应用和各大深度学习框架提供加速。A100 适用于桌面、服务器以及云服务，不仅能显著提升性能，更可以节约成本。

面向企业的优化软件和服务



各类深度学习框架

mxnet

PYTORCH

APACHE
SPARK

TensorFlow

2000 余款 GPU 加速应用



Altair nanoFluidX



Altair ultraFluidX



AMBER



ANSYS Fluent



DS SIMULIA Abaqus



GAUSSIAN



GROMACS



NAMD



OpenFOAM



VASP



WRF

以上图片仅供参考

