

Ceph 安装教程

官方手册链接: <https://docs.ceph.com/en/latest/>

一、安装 Cephadm

安装依赖 (所有节点均需要安装)

Shell

```
1 apt install python3 systemd docker.io chrony lvm2 curl ceph-volume
```

cephadmin有两种安装方式,一种是直接使用包管理器安装,一种是通过curl下载。

仓库地址: <https://download.ceph.com/>

ubuntu

Shell

```
1 echo "deb https://download.ceph.com/debian-quincy/ $(lsb_release -sc) main" >> /etc/apt/sources.list.d/ceph.list
2
3 apt install -y cephadm
```

centos

Shell

```
1 CEPH_RELEASE=18.2.0
2 curl --silent --remote-name --location https://download.ceph.com/rpm
  -${CEPH_RELEASE}/el9/noarch/cephadm
3
4 chmod +x cephadm
5
6 ./cephadm <arguments...>
7
8 ./cephadm add-repo --release |stable-release|
9
10 ./cephadm install
11
12 which cephadm
13
14 /usr/sbin/cephadm
```

二、初始化 Ceph

初始化将会：

在本机上创建监控进程和管理进程

为 Ceph 集群生成一个新的 SSH 密钥，并将其添加到根用户的 `/root/.ssh/authorized_keys` 文件中。

将公钥的内容复制到 `/etc/ceph/ceph.pub` 文件中。

将一个简化的配置文件写入到 `/etc/ceph/ceph.conf` 目录下。此文件是与 Ceph 服务进程进行通信所必需的。

将客户端管理员（具有特权权限！）的密钥副本写入到 `/etc/ceph/ceph.client.admin.keyring` 中。

添加 “_admin” 标签给初始化主机。默认情况下，带有此标签的任何主机都将获得 `/etc/ceph/ceph.conf` 和 `/etc/ceph/ceph.client.admin.keyring` 的副本。

更多Ceph初始化内容以及后缀参数，见官网手册。

Shell

```
1 cephadm bootstrap --mon-ip <mon-ip>
```

初始化后，已经可以使用cephadm和ceph进行交互，但是为了更加便捷的维护和操作ceph，建议执行下方操作，下载ceph cli客户端。

Shell

```
1 cephadm add-repo --release tentacle
2 cephadm install ceph-common
3 ceph -v
4 ceph version
5 ceph status
```

ceph建议每个集群存在3个或5个监控进程，分布在不同的节点上。ceph默认情况下，会自动随着集群扩大，自动部署监控进程到节点上。但通常增长到5个节点后，就不再会增加。如何手动配置监控节点，看后面详细模块。

三、添加节点和硬盘

Shell

```
1 #设置ceph免密登录
2 ssh-copy-id -f -i /etc/ceph/ceph.pub root@<ip>
3
4 #添加节点
5 ceph orch host add <host> <ip>
6
7 #列出可用硬盘
8 ceph orch device ls
9
10 #添加硬盘
11 ceph orch daemon add osd <host>:<device-path>
```

四、创建 pool

Shell

```
1 #创建副本池
2 ceph osd pool create <poolname>
3
4 #创建ec池
5 ceph osd pool create <ecpool> erasure
6
7 #运行ec overwrites
8 ceph osd pool set <EC_DATA_POOL_NAME> allow_ec_overwrites true
```

四、创建 CephFS

CephFS需要一个或多个MDS服务运行在集群中。使用ceph fs volume会自动创建MDS。使用

--placement="<placement spec>"参数也可以指定MDS服务部署的范围

Shell

```
1 #快速创建
2 ceph fs volume create cephfs
3
4 #自定义创建cephfs，可以选择使用的池
5 ceph fs new <fs_name> <metadata_pool> <data_pool>
```

客户端挂载

Shell

```
1 mkdir -p -m 755 /etc/ceph
2
3 ssh {user}@{mon-host} "sudo ceph config generate-minimal-conf" | sudo tee /etc/ceph/ceph.conf
4
5 chmod 644 /etc/ceph/ceph.conf
6
7 ssh {user}@{mon-host} "sudo ceph fs authorize cephfs client.foo / rw"
  | sudo tee /etc/ceph/ceph.client.foo.keyring
8
9 chmod 600 /etc/ceph/ceph.client.foo.keyring
10
11 mkdir /mnt/mycephfs
12
13 mount -t ceph <name>@<fsid>.<fs_name>=/ /mnt/mycephfs
14
15 #持久化挂载
16 cephuser@.cephfs=/ /mnt/ceph ceph mon_addr=192.168.0.1:6789,noatime,_netdev 0 0
```

五、创建 NFS

参考链接: <https://docs.ceph.com/en/latest/mgr/nfs/#>

ceph的nfs需要依赖于CephFS或者RGW

依赖CephFS教程:

加--ingress是为了提供一个统一入口服务, 提供高可用和负载均衡。他有如下几种模式:

--ingress-mode keepalive-only: 提供一个虚拟ip, 和一个后台nfs server绑定。只能做到高可用, 做不到负载均衡。

--ingress-mode haproxy-standard: 默认模式。通过虚拟ip, 实现后台的高可用和负载均衡。

--ingress-mode haproxy-protocol: NFS Ganesha版本5.0及以上支持。功能最完全, 除上述功能。还可让nfs server查看到nfs客户端的ip, 通过ip进行限制。

Shell

```
1 #创建nfs集群
2 ceph nfs cluster create ceph-nfs --ingress --virtual_ip <virtual_ip>
3
4 #创建nfs集群export(--path=/ceph-nfs,cephfs文件系统里要提前创建这个目录结构)
5 ceph nfs export create cephfs --cluster-id ceph-nfs --fsname cephfs --p
  pseudo-path /ceph-nfs --path=/ceph-nfs
6
7 #挂载
8 mount -t nfs <ganesha-host-name>:<pseudo_path> <mount-point>
```

其他：

(一)OSD 相关命令

Shell

```
1 #添加硬盘
2 ceph orch daemon add osd <host>:<device-path>
3
4 #列出硬盘树结构
5 ceph osd tree
6
7 #列出硬盘
8 ceph orch ps --daemon-type osd
9
10 #列出硬盘
11 ceph orch device ls [--hostname=...] [--wide] [--refresh]
12
13 #优雅删除硬盘
14 ceph orch osd rm <osd_id(s)> [--replace] [--force] [--zap]
15
16 #快速删除硬盘
17 ceph osd purge <osd_id(s)> --yes-i-really-mean-it
18
19 #清理硬盘
20 ceph-volume lvm zap /dev/sdb --destroy
21
22 #使用cephadm停掉某个osd进程
23 ceph orch daemon stop osd.0
24
25 #使用cephadm清除某个osd进程
26 ceph orch daemon rm osd.0 --force
```

(二)Cephfs

Shell

```
1 #删除cephfs
2 ceph fs set <myfs> down true
3 ceph fs rm <myfs> --yes-i-really-mean-it
4
5 #快速删除文件系统
6 ceph fs fail <fs_name> {--yes-i-really-mean-it}
7
8 #查看池信息
9 ceph fs status cephfs-ec
```

(三)POOL

参考文章: <https://docs.ceph.com/en/latest/rados/operations/pools/>

Shell

```
1 #查看池信息
2 ceph osd pool get cephfsec_data all
3
4 #创建ec池
5 ceph osd pool create <ecpool> erasure
6
7 #列出池
8 ceph osd pool ls
9
10 #列出池和ID
11 ceph osd lspools
12
13 #列出池的详细信息
14 ceph osd pool ls detail
15
16 #删除某个池
17 ceph osd pool delete {pool-name} [{pool-name} --yes-i-really-really-mean-it]
18
19 #重命名某个池
20 ceph osd pool rename {current-pool-name} {new-pool-name}
21
22 #查看池的利用率
23 rados df
24
25 #查看池的IO信息
26 ceph osd pool stats [{pool-name}]
27
28 #创建池的快照
29 ceph osd pool mksnap {pool-name} {snap-name}
30
31 #删除池的快照
32 ceph osd pool rmsnap {pool-name} {snap-name}
33
34 #设置池的信息
35 ceph osd pool set {pool-name} {key} {value}
36
37 #获取池的设置
38 ceph osd pool get {pool-name} {key}
```

```
39
40 #查看池的副本信息
41 ceph osd dump | grep 'replicated size'
42
43 #设置pool的replica为1
44 ceph config set mon mon_allow_pool_size_one true;
45 ceph osd pool set mypoolname size 1
46
47 #删除池
48 ceph config set mon mon_allow_pool_delete true
49 ceph osd pool delete <cephfsec_data> <cephfsec_data> --yes-i-really-really-mean-it
50 ceph config set mon mon_allow_pool_delete false
```

(四)关于 Replica 和 Erasure 的选择

replica：性能好，适合对io性能有要求的场景。但空间利用率低。ceph默认使用。

erasure：空间利用率高，但io性能较低，运维复杂。本质是把数据分为多块，并使用额外的校验码。

两者对比尤其在写入性能上差距会大。

数据库、小文件、VM等无条件选择replica

冷数据、备份、视频等，可以选择EC

通常情况下可以同时做replica池和ec池。同时做两种池，在物理层面上，可以划分也可以不划分。

如果要物理层面分的话，可以nvme用作热数据池，hdd用作冷数据池。在大规模集群中，也存在以整个节点为单位进行冷热区分的。

集群规模	2+2	理由
≤4 台	2+2	安全第一
5-7 台	3+1	性价比最佳
≥6 台	4+2	空间 + 可靠性平衡
≥10 台	8+3/6+3	极致容量

(五)NFS 相关命令

Shell

```
1 #查看nfs集群ip
2 ceph nfs cluster info [<cluster_id>]
3
4 #查看nfs和ingress服务状态
5 ceph orch ls --service_name=nfs.<cluster_id>
6 ceph orch ls --service_name=ingress.nfs.<cluster_id>
7
8 #删除nfs集群
9 ceph nfs cluster rm <cluster_id>
10
11 #删除export
12 ceph nfs export rm <cluster_id> <pseudo_path>
13
14 #列出export
15 ceph nfs export ls <cluster_id> [--detailed]
16
17 #展示export信息
18 ceph nfs export info <cluster_id> <pseudo_path>
19
20 #修改nfs集群配置
21 ceph orch ls --service-name nfs.foo --export > nfs.ceph-nfs.yaml
22 vi nfs.ceph-nfs.yaml
23 ceph orch apply -i nfs.ceph-nfs.yaml
24
25 #列出nfs集群
26 ceph nfs cluster ls
27
28
```

(六)Bluestore 分离式部署

参考链接：<https://docs.ceph.com/en/latest/rados/configuration/bluestore-config-ref/>
分离的目的是用高速设备（NVMe SSD）加速低速设备（HDD）的元数据操作，从而提升整体性能。

分离包括三部分：

data：数据部分

block.db：元数据，小IO，随机，读多

block.wal: WAL事务日志, 极小IO

写流程:

Client → block.wal (保证不丢) → block.db (更新映射) → data (写真实数据)

读流程:

Client → block.db (查位置) → data (读数据)

Shell

```
1 ceph-volume lvm prepare --bluestore --data <device> --block.wal <wal-device> --block.db <db-device>
```

(七)CRUSH Maps

参考链接: <https://docs.ceph.com/en/latest/rados/operations/crush-map/#crush-structure>

CRUSH是ceph的数据分布算法, 它解决的问题是:

- 1、数据放在哪里
- 2、副本怎么分散
- 3、集群变动时, 数据怎么处理

传统做法: 传统的做法使用的是中心表, 读写数据时, 需要先经过中心表的元数据, 才能得知实际数据的信息。这种做法的风险是, 一旦中心表丢失, 集群数据将损毁。并且很容易卡元数据的瓶颈。

CRUSH做法: 对象名+规则+拓扑 = 算出来的OSD列表, 没有中心表。算法本身就是映射关系。

同时OSD并不是CRUSH的计算单位, PG才是。

CRUSH BUCKET: 逻辑层面的设备集合, 比如可以从osd区分、host区分、也可以通过rack区分, 或者是root整个区域做区分。

Shell

```
1 #列出当前的crush规则
2 ceph osd crush rule ls
3
4 #给某个盘设置class
5 ceph osd crush set-device-class <class> <osd-name>
6
7 #清除某个盘的class
8 ceph osd crush rm-device-class <osd-name>
9
10 #创建crush规则 (replica池)
11 ceph osd crush rule create-replicated <rule-name> <root> <failure-domain> <class>
12
13 #创建crush profile (ec池)
14 ceph osd erasure-code-profile set ec_hdd k=4 m=2 crush-root=default crush-failure-domain=host crush-device-class=hdd
15
16 #创建crush规则 (ec池) (ec规则基于profile)
17 ceph osd crush rule create-erasure {name} {profile-name}
18
19 #列出ec crush profile
20 ceph osd erasure-code-profile ls
21
22 #设置某个池子的crush规则
23 ceph osd pool set <pool-name> crush_rule <rule-name>
24
25 #查看某个池的crush策略
26 ceph osd pool get test crush_rule
27
28 #删除crush规则
29 ceph osd crush rule rm {rule-name}
```

(八)PG 理解

PG是一组对象的命运共同体，一堆对象一起映射，一起迁移，一起被recovery，一起被CRUSH算位置。Object → PG → OSD set

为什么一定要有PG？

如果没有PG，海量的对象，每个对象的操作都需要经过CRUSH计算，会导致计算爆炸。PG的作用就是把对象放置到有限的组内，已组为单位来进行计算。

PG太少会怎样？

每个PG很“胖”。recovery粗粒度。IO hotspot明显。

PG太多会怎样？

OSD内存爆炸。peering慢。启停OSD慢

常用命令

Shell

```
1 #查看ceph节点信息
2 ceph orch host ls
3
4 #给节点添加_admin标签，这样才允许在该节点跑管理相关的组件
5 ceph orch host label add <host> _admin
6
7 #查看ceph模块状态
8 ceph mgr module ls
9
10 #查看ceph硬盘信息
11 ceph orch device ls
12
13 #查看已有的cephX用户
14 ceph auth list | grep client
15
16 #查看集群健康信息
17 ceph health detail
18
19 #查看元数据节点状态
20 ceph mds stat
```

卸载 ceph 教程

Shell

```
1 cephadm rm-cluster --force --zap-osds
2 dnf remove -y ceph\*
3 rm -rf /etc/ceph /var/lib/ceph /var/log/ceph /run/ceph
4 wipefs -a /dev/sdX
5 reboot
```