

使用 evalscope 压测模型

目录

使用 evalscope 压测模型	1
一、配置说明	2
1.1 配置	2
1.2 模型	2
二、利用 evalscope 压测模型	3
2.1 安装 evalscope 压测工具	3
2.2 16 并发固定数据集	3
2.3 random 数据集	3
2.4 公开数据集 (openqa 等)	4
三、测试数据分析	5
3.1 16 并发固定数据总结	5
3.2 random 数据总结	6
3.3 公开数据总结	7

一、配置说明

1.1 配置

系统：ubuntu22.04

此次配置使用显卡为 NVIDIA GeForce RTX 4090 （8 张）

1.2 模型

模型：gemma-4-31B-it

二、利用 evalscope 压测模型

2.1 安装 evalscope 压测工具

```
pip install evalscope[perf] -U -i https://mirrors.aliyun.com/pypi/simple/
```

2.2 16 并发固定数据集

```
evalscope perf \  
  --url http://localhost:8001/v1/chat/completions \  
  --model gemma-4-31B-it \  
  --api openai \  
  --parallel 16 \  
  --number 500 \  
  --prompt "请详细介绍一下人工智能的发展历史" \  
  --max-tokens 2048 \  
  --stream
```

2.3 random 数据集

```
evalscope perf \  
  --url http://localhost:8001/v1/chat/completions \  
  --model gemma-4-31B-it \  
  --api openai \  
  --parallel 16 \  
  --number 500 \  
  --dataset random \  
  --min-prompt-length 64 \  
  --max-prompt-length 1024 \  
  --max-tokens 2048 \  
  --stream
```


```
--tokenizer-path /model/gemma-4-31B-it \  
--warmup 10 \  
--stream
```

2.4 公开数据集 (openqa 等)

```
evalscope perf \  
  --url http://localhost:8001/v1/chat/completions \  
  --model gemma-4-31B-it \  
  --api openai \  
  --parallel 16 \  
  --number 500 \  
  --dataset openqa \  
  --max-tokens 2048 \  
  --stream
```


三、测试数据分析

3.1 16 并发固定数据总结




指标类别	关键数值
全局吞吐	749.52 tokens/s
平均延迟	31.17 s
首字延迟 (TTFB)	88.6 ms
单请求解码速度	47.71 tokens/s

3.2 random 数据总结



指标类别	关键数值
全局吞吐	454.76 tokens/s
平均延迟	5.56 s
首字延迟 (TTFB)	33.2 ms
单请求解码速度	30.14 tokens/s

3.3 公开数据总结



指标类别	关键数值
全局吞吐	759.82 tokens/s
平均延迟	14.90 s
首字延迟 (TTFB)	83.7 ms
单请求解码速度	48.85 tokens/s