

DeepSeek-R1 本地部署时不同版本对 硬件配置的要求

作者：沈小然

日期：2025-2-6

修改：2025-2-10

目录

1	ollama 官方提供的 DeepSeek-R1 蒸馏模型信息推出不同版本对硬件配置的要求.....	3
2	Ollama 平台提供的蒸馏模型对硬件配置的要求	4
2.1	DeepSeek-R1-1.5B.....	4
2.2	DeepSeek-R1-7B	4
2.3	DeepSeek-R1-8B	4
2.4	DeepSeek-R1-14B.....	5
2.5	DeepSeek-R1-32B.....	5
2.6	DeepSeek-R1-70B.....	5
2.7	DeepSeek-R1-671B.....	6
3	全量模型对硬件 GPU 配置的要求.....	6

1 ollama 官方提供的 DeepSeek-R1 蒸馏模型信息推出不同版本对硬件配置的要求

deepseek-r1

DeepSeek's first-generation of reasoning models with comparable performance to OpenAI-o1, including six dense models distilled from DeepSeek-R1 based on Llama and Qwen.

1.5b 7b 8b 14b 32b 70b 671b

9.3M Pulls Updated 2 weeks ago

7b

28 Tags

ollama run deepseek-r1

1.5b	1.1GB	0a8c26691023 · 4.7GB
7b	4.7GB	parameters 7.62B · quantization Q4_K_M 4.7GB
8b	4.9GB	
14b	9.0GB	
32b	20GB	
70b	43GB	
671b	404GB	

蒸馏模型(Distilled Models)

对于没有高端 GPU 的开发者和研究人员，DeepSeek-R1-Distill 模型提供了一个优秀的替代方案。这些蒸馏版的 DeepSeek-R1 旨在保留显著的推理和问题解决能力，同时减少参数大小和计算需求。

蒸馏模型的优势

- 降低硬件要求：蒸馏模型如 DeepSeek-R1-Distill-Qwen-1.5B 的 VRAM 需求从 3.5 GB 起，可以在更易获得的 GPU 上运行。
- 高效且强大：尽管尺寸更小，蒸馏模型依然保持强大的推理能力，通常在性能上优于其他架构中类似大小的模型。
- 成本效益高：蒸馏模型使得在低端硬件上进行实验和部署成为可能，节省了在昂贵的多 GPU 配置上的开销。

根据 Ollama 平台提供的 DeepSeek-R1 模型信息，以下是不同参数量模型的本地部署硬件要求和适用场景分析。

注：部分数据基于模型通用需求推测，具体以实际部署测试为准。

2 Ollama 平台提供的蒸馏模型对硬件配置的要求

2.1 DeepSeek-R1-1.5B

CPU：最低 4 核（推荐 Intel/AMD 多核处理器）

内存：8GB+

硬盘：3GB+ 存储空间（模型文件约 1.5-2GB），推荐 10GB 以上 SSD

GPU：非必需（纯 CPU 推理），若 GPU 加速可选 4GB+ 显存（如 GTX 1650）

场景：

低资源设备部署（如树莓派、旧款笔记本）

实时文本生成（聊天机器人、简单问答）

嵌入式系统或物联网设备

2.2 DeepSeek-R1-7B

CPU：8 核以上（推荐现代多核 CPU）

内存：16GB+

硬盘：8GB+（模型文件约 5-6GB），推荐 20GB 以上 SSD

GPU：推荐 8GB+ 显存（如 RTX 3070/4060）

场景：

本地开发测试（中小型企业）

中等复杂度 NLP 任务（文本摘要、翻译）

轻量级多轮对话系统

2.3 DeepSeek-R1-8B

硬件需求：与 7B 相近，略高 10-20%

CPU：8 核以上（推荐现代多核 CPU）

内存：16GB+

场景：

需更高精度的轻量级任务（如代码生成、逻辑推理）

2.4 DeepSeek-R1-14B

CPU：12 核以上

内存：32GB+

硬盘：15GB+，推荐 50GB 以上 SSD

GPU：16GB+ 显存（如 RTX 4090 或 A5000）

场景：

企业级复杂任务（合同分析、报告生成）

长文本理解与生成（书籍/论文辅助写作）

2.5 DeepSeek-R1-32B

CPU：16 核以上（如 AMD Ryzen 9 或 Intel i9）

内存：64GB+

硬盘：50GB+，推荐 100GB 以上 SSD

GPU：24GB+ 显存（如 A100 40GB 或双卡 RTX 3090 48G）

场景：

高精度专业领域任务（医疗/法律咨询）

多模态任务预处理（需结合其他框架）

2.6 DeepSeek-R1-70B

CPU：32 核以上，推荐 64 核（服务器级 CPU）

内存：128GB+

硬盘：70GB+，推荐 200GB 以上 SSD

GPU：多卡并行（如 2xA100 80GB 或 4xRTX 4090 96G）

场景：

科研机构/大型企业（金融预测、大规模数据分析）

高复杂度生成任务（创意写作、算法设计）

2.7 DeepSeek-R1-671B（FP8）

CPU：基础至少 64 核，推荐 128 核以上（服务器集群）

内存：512GB+

硬盘：600GB+，推荐 1TB 以上 NVMe SSD

GPU：多节点分布式训练（如 8x A100/H100 640GB）

场景：

国家级/超大规模 AI 研究（如气候建模、基因组分析）

通用人工智能（AGI）探索

总结：选择合适的 DeepSeek 版本不仅要考虑硬件配置，还要根据实际应用场景来决定。建议先从较小的模型开始尝试，逐步升级到更大的模型。这样可以在确保性能的同时，避免资源浪费。

3 全量模型对硬件 GPU 配置的要求

全量模型的精度是 FP16 精度

Model	参数（B）	VRAM 要求（GB）	推荐 GPU
DeepSeek-R1	671B	约 1,543 GB	Multi-GPU setup (e.g., NVIDIA A100/H100 80GB x16)
DeepSeek-R1- Distill-Qwen-1.5B	1.5B	约 3.9 GB	NVIDIA RTX 3060 12GB or higher
DeepSeek-R1- Distill-Qwen-7B	7B	约 18 GB	NVIDIA RTX 4090 24GB or higher
DeepSeek-R1- Distill-Llama-8B	8B	约 21 GB	NVIDIA RTX 4090 24GB or higher
DeepSeek-R1- Distill-Qwen-14B	14B	约 36 GB	Multi-GPU setup (e.g., NVIDIA RTX 4090 x2)

DeepSeek-R1- Distill-Qwen-32B	32B	约 82 GB	Multi-GPU setup (e.g., NVIDIA RTX 4090 x4)
DeepSeek-R1- Distill-Llama-70B	70B	约 181 GB	Multi-GPU setup (e.g., NVIDIA A100/H100 80GB x3)