

DGX SPARK 技术部调研报告


作者：朴赛技术部

一、产品介绍：

由 NVIDIA GB10 Grace Blackwell 超级芯片驱动，NVIDIA DGX Spark 以节能高效和紧凑外观，具备 1 petaFLOP1 的 AI 性能。借助预装的 NVIDIA AI 软件栈和 128 GB 内存，开发者可以对 DeepSeek、Meta、Google 和其他公司的最新一代推理 AI 模型进行原型制作、微调 and 推理，这些模型在本地具有多达 2000 亿个参数，并无缝部署到数据中心或云端。

二、产品外观：





三、适用场景：

部署、开发、微调大模型，数据分析，开发机器人、智能城市、计算机视觉。

四、优势总结：

小巧轻便，具有 128G 统一内存（cpu、gpu 共用，基于 NVLINK C2C 技术）。能够让开发者快速进行 200B 及以下模型的开发、推理、微调、数据分析。同时支持将 2 个机器进行快速集群化，以应对 400B 模型场景。另一方面，搭载的 DGX OS 系统，预装了 NVIDIA AI 软件堆栈，例如 NVIDIA Container Toolkit（docker 无缝使用 GPU）、DGX Dashboard，使开发者可以开箱即用，立即投入 AI 研发中。

五、产品参数：

组成	配置
显卡	英伟达 Blackwell GB10
处理器	20 核 Grace 处理器（10 个 Cortex-X925 性能核+10 个 Cortex-A725 能效核）
内存 (CPU+GPU 共用)	128G 低功耗版 DDR5 统一内存 4266 MHz 273 GB/s 内存带宽 16 通道
存储	1 TB 或 4 TB NVMe M.2 存储
网络	1x10 GbE 电口 1xConnectX-7 网卡 双端口 200G Wi-Fi 7 蓝牙 5.4
接口	4xUSB Type-C 1xHDMI
视频处理引擎	1x 视频编码引擎,1x 视频解码引擎
尺寸	长 150mm 宽 150mm 高 50.5mm
电源	240W

六、系统信息：

模块	详细信息
操作系统	NVIDIA DGX OS 7.2.3（定制化 Ubuntu 24.04）
驱动版本	580.95.05
CUDA 版本	13.0.2
预装软件	NVIDIA DGX OS、CUDA,cuDNN、Docker、 NVIDIA Container Runtime、NGC

七、性能参数

性能项	版本
算力	1PFLOPS-FP4-使用稀疏
CUDA 核心	6144
内存带宽	273 GB/s
内存频率	4266MHz
网络带宽	双端口 200Gb/s


八、AI 场景能力

组件	版本
模型大小	最大可支持 200B 模型（FP4 精度）、70B 大模型微调。
框架支持	TensorFlow, PyTorch, TRT-LLM 等
适用场景	部署、开发、微调大模型、数据科学
模型举例——推理	DeepSeek-R1-Distill-Llama-70B-FP8-dynamic QWEN3-32B-FP16
模型举例——训练	DeepSeek-R1-Distill-Llama-70B

九、自带仪表盘

DGX Spark 配备了一个内置仪表盘，可提供系统当前运行指标的概览，支持应用更新、更改部分系统设置，并可访问本地的 **Jupyter Notebook**，同时支持管理 **NVIDIA** 驱动、管理固件更新、管理系统更新等，使用户使用更加便捷。具体使用方式为访问地址：

<http://localhost:11000>



十、如何集群化 2 台 spark

技术部已调研完毕，此处不予展示。